

¿Gustará este juego?

Predicción de la recepción de videojuegos en Steam con Machine Learning

● Isaac Frías · Project Break II — The Bridge, Data Science

122.611 juegos analizados · clasificación binaria · ROC-AUC 0.776 en test

Lanzar un juego es una apuesta cara

- Un estudio invierte años y millones antes de saber si el público lo aceptará.
- Las reseñas de Steam son el termómetro de esa acogida... pero llegan tarde.
- Pregunta: ¿podemos anticiparla con lo que sí se decide antes del lanzamiento?

Objetivo: estimar la probabilidad de buena acogida para ajustar esas palancas antes de lanzar.

Decisiones que sí controla el estudio

- Precio y modelo (F2P / pago)
- Género y categorías
- Plataformas soportadas
- Idiomas y localización

Steam Games Dataset

122.611

juegos en el catálogo bruto

39

columnas por juego

30.620

juegos usables para modelar

Un bug real del dataset


La cabecera del CSV junta 'Discount' y 'DLC count' en un solo nombre, lo que desplaza todas las columnas siguientes. Lo detecté comparando datos con la web de Steam y lo reparo al cargar, forzando los nombres correctos en `data_loader.py`.

Construyendo la variable objetivo

El dataset no trae una columna «bien recibido». La defino yo:

- 1 Solo juegos con ≥ 50 reseñas — con 3 reseñas el porcentaje no significa nada
- 2 `repcion_positiva = 1` si $\geq 70\%$ de reseñas positivas
- 3 Resultado: 30.620 juegos, clases desbalanceadas 75 / 25

→ Por eso la métrica es ROC-AUC y F1, nunca accuracy: prediciendo siempre «positiva» acertaría un 75 % sin aprender nada.



Evitar la fuga de información

El target se calcula con las reseñas. Si deajo entrar variables derivadas de esas mismas reseñas, el modelo «hace trampa»: acierta casi todo y no sirve para nada en el mundo real.



Excluidas del modelo

- Positive · Negative
- total_reviews · pct_positivas
- User score
- Recommendations

Lo que sí usa el modelo

- Precio y es_f2p
- Género principal y n° de géneros
- N° de idiomas y categorías
- Plataformas (Win/Mac/Linux)
- Logros, DLCs, edad mínima
- Tiempo de juego medio, Peak CCU
- Antigüedad del lanzamiento

Qué dicen los datos



Los juegos de pago se reciben mejor que los F2P (76 % vs 69 %) y el género separa con claridad: Adventure ~81 %, Action ~73 %. Hay señal real que el modelo puede aprovechar.

De datos crudos a matriz de entrenamiento

1

Split estratificado

80/20 manteniendo la proporción 75/25

2

Imputación

mediana en numéricas, constante en categóricas

3

log1p + escalado

precio, playtime y Peak CCU tienen colas largas

4

One-Hot


género principal, agrupando categorías raras

18 → 33

features tras el encoding

Todo dentro de un Pipeline de scikit-learn: el preprocesado se reajusta en cada fold, así que no se filtra información del test durante la validación.

Comparativa de modelos





Validación cruzada 5-fold

- Dummy (baseline) — 0.50
- Regresión Logística — 0.70
- Random Forest — 0.75
- HistGradientBoosting — 0.76

El baseline marca el suelo (0.50). Todo modelo real lo bate; gana el boosting.

Evaluación final sobre datos no vistos



0.776

ROC-AUC en test


0.869

F1 en test

Optimizado con GridSearchCV (learning_rate 0.1, max_iter 300) sobre la misma CV estratificada.

El test no se toca hasta este punto: es la única medida honesta de cómo generaliza el modelo.

Qué mueve la predicción




Importancia por permutación

Mide cuánto empeora el ROC-AUC al barajar cada variable. Es agnóstica al modelo, así que funciona con boosting, y se lee sobre las variables originales.

- Tiempo de juego medio
- Precio
- Número de idiomas
- Modelo de negocio (F2P)
- Género principal

El modelo no decide: cuantifica el intercambio



El modelo devuelve una probabilidad. Dónde cortar lo decide el negocio, según qué error duele más:

Inversor selectivo

Sube el umbral: menos juegos elegidos, pero más aciertos entre ellos.

Cribado inicial

Baja el umbral: no se escapa ningún candidato prometedor.

Este es el puente entre la métrica y la decisión real de un estudio.

CONCLUSIONES

Qué he aprendido y dónde está el límite

Lo que funciona

- Se puede anticipar la acogida sin usar reseñas
- ROC-AUC 0.776 frente a 0.50 del baseline
- Pipeline reproducible y sin fuga de datos

Limitaciones (honestas)

- El techo lo pone la señal disponible
- Calidad real, marketing y timing no están en los datos
- Malla de búsqueda reducida por tiempo de cómputo

Siguientes pasos: features desde los Tags · calibración de probabilidades · ajuste del umbral según el coste de negocio

«Un modelo honesto que acierta el 77 % es más útil que uno perfecto que hace trampa.»

Gracias

Código, notebooks y modelo:

github.com/IsaacFrr/ML_steam_reception

Isaac Frías · The Bridge — Data Science